VÝSLEDOK EXPERIMENTOV

Formálna štruktúra pomáha. Samotné symboly nestačia.

B1, B2, S0 a Llama 3 8B | Anglické sylogizmy | 191 testovacích príkladov

76,54 %

DeBERTa: priemer 5 seedov

SD 3,06 p. b.; +11,10 p. b. oproti B1.

+12,57 p. b.

Llama: kanonický zápis

79,58 % oproti 67,02 % na pôvodnom texte.

90,58 %

S0: najvyššia presnosť

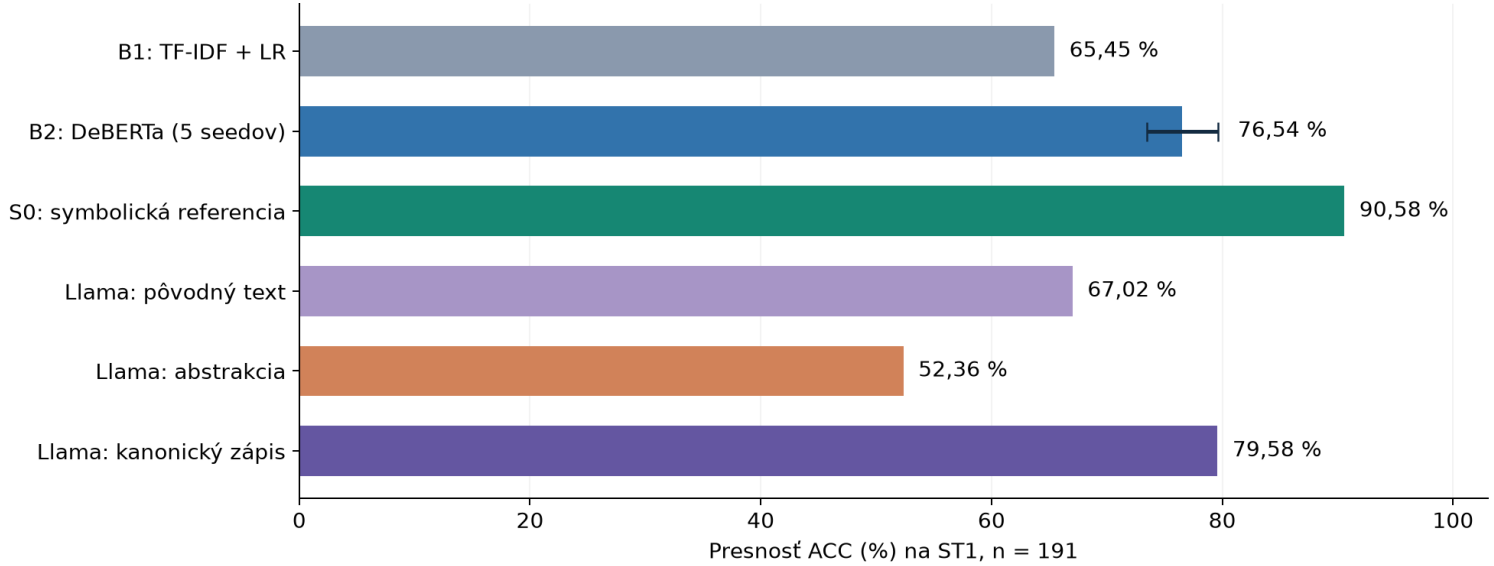
Symbolická referencia na celom teste; nie LLM.

Negatívny, ale dôležitý výsledok: jednoduchá abstrakcia znížila presnosť Llamy na 52,36 %. Model v tomto variante označil 185 zo 191 argumentov za platné.

Všetkých 16 exportovaných neurónových vyhodnotení bolo prepočítaných z predikcií. Nenašli sa nezrovnalosti v kontrolovaných metrikách, rozdeleniach dát ani exportoch.

Presnosť: symbolický systém vedie, DeBERTa prekonáva B1

B2: priemer ± smerodajná odchýlka medzi seedmi. Ostatné metódy: jeden beh; bez odhadu variability medzi behmi.

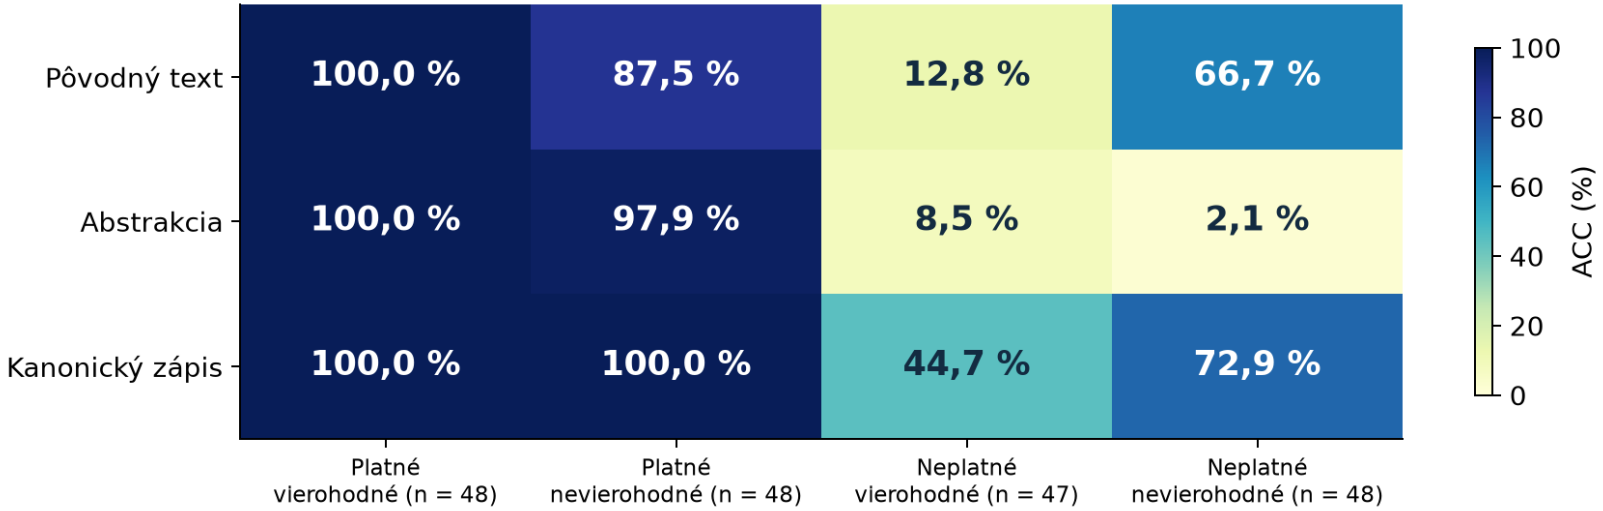


Metóda	ACC (%)	TCE (nižšie lepšie)	CS (vyššie lepšie)
B1 / TF-IDF + LR	65,45	10,90	18,82
B2 / DeBERTa, priemer	76,54	9,37	24,13
S0 / symbolická referencia	90,58	10,42	26,37

S0 má najvyššiu ACC, nie najnižšie TCE vo všetkých jednotlivých behoch. ACC, TCE a CS sú odlišné kritériá.

Abstrakcia vedie k odpovedi „platný“ takmer vždy

Llama 3 8B Instruct, NF4 4-bit, rovnaký prompt v1, greedy decoding; žiadne nejednoznačné odpovede.



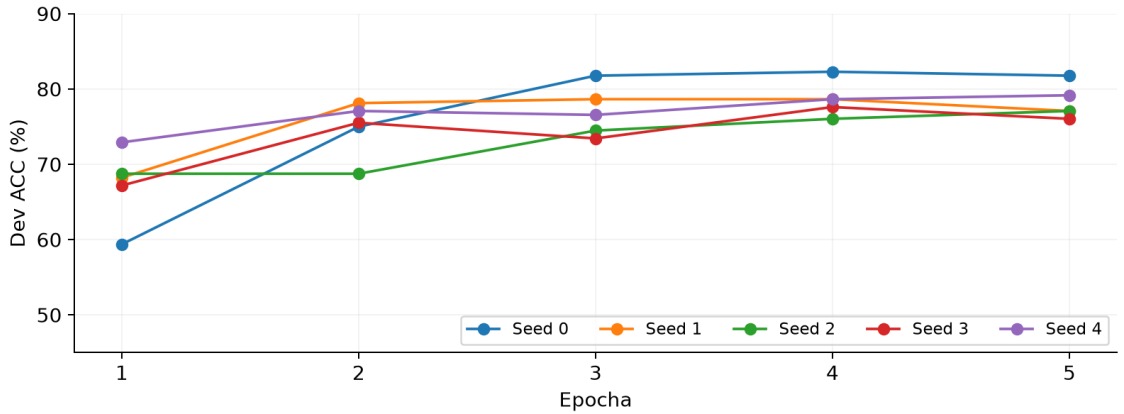
Vstup Llamy	ACC (%)	TCE	CS	Predikcie „platný“
Pôvodný text	67,02	43,62	13,97	147 / 191
Abstrakcia	52,36	48,96	10,66	185 / 191
Kanonický zápis	79,58	27,66	18,27	135 / 191

Kanonický vstup zlepšil ACC, ale jeho CS (18,27) zostáva pod B1 (18,82). Vysoké TCE abstrakcie súvisí najmä s rozdielom medzi platnými a neplatnými argumentmi, nie iba s vierohodnosťou.

DeBERTa sa učí; výsledok závisí od náhodného seedu

5 epoch, learning rate 2e-5, efektívna dávka 16. Checkpoint podľa najvyššej dev ACC, pri zhode skoršia epocha.

Seed	Epocha	Dev ACC	Test ACC	Test TCE	Test CS
0	4	82,29	79,58	7,58	25,27
1	3	78,65	72,77	3,12	30,11
2	5	77,08	74,35	11,46	21,11
3	4	77,60	76,44	8,67	23,39
4	5	79,17	79,58	16,00	20,76



Test ACC: 76,54 ± 3,06 %
Rozsah: 72,77 až 79,58 %.

SD opisuje rozdiely medzi seedmi, nie 95 % interval spoľahlivosti.

Seed 0 má najvyššiu dev ACC. Seed 1 má najvyššie testové CS (30,11), ale výber víťaza podľa testu by bol metodicky nesprávny.

Priemer CS cez seedy = 24,13 ± 3,81.
Priemer jednotlivých CS nie je CS vypočítané z priemernej ACC a TCE.

Čísla sú konzistentné. Audit neznamená nový GPU experiment.

1308 automatických kontrol; 0 zistených nezrovnalostí v kontrolovaných položkách.

Čo sa overilo

- Úplnosť ID: 192 dev a 191 test príkladov v každom behu.
- ACC, TCE, CS, confusion matrix a 95 % bootstrap intervaly.
- Hashe dát a vstupov Llamy; štítky zo surových odpovedí.
- Päť epoch každého seedu a výber najlepšej podľa dev.
- Zhoda journalu, predikcií, submission a súhrnnej tabuľky.

Čo archív nedokazuje

- Neobsahuje váhy modelov ani kompletné konzolové logy.
- Neobsahuje snapshot tréningového kódu ani úplný pip freeze.
- Nemožno nezávisle potvrdiť presný GPU typ alebo absenciu ladenia podľa testu.
- Preskúmali sa predikcie; tréning sa tu znovu nespúšťal.

Párové porovnania na teste (exploračné): kanonická Llama oproti pôvodnej opravila 28 príkladov a pokazila 4. Presný McNemarov test: p = 0,0000193; po Holmovej korekcii troch porovnaní p = 0,0000386.

Výsledok podporuje rozdiel na tejto vzorke; nezaručuje prenos na iné prompty, modely alebo jazyky. Intervaly spoľahlivosti a ostatné párové porovnania sú v audit.json.

Čo môžeme povedať pri prezentácii

Výsledky sa týkajú ST1. Archív neobsahuje nové neurónové experimenty pre ST2, ST3 ani ST4.

1. Doladenie pomohlo. DeBERTa prekonala jednoduchý textový baseline v každom z piatich seedov. Priemerný rozdiel v testovej presnosti je +11,10 percentuálneho bodu.

2. Záleží na forme vstupu. Kanonický zápis zvýšil presnosť Llamy, kým samotná abstrakcia ju znížila. Hypotéza „odstránenie konkrétnych pojmov automaticky pomáha“ sa v tomto experimente nepotvrdila.

3. Formálna dedukcia zostáva silnou referenciou. S0 dosiahol najvyššiu ACC. Parser však pokrýva len 160/191 príkladov; S0 pri ostatných predikuje neplatnosť.

Ďalší krok: na dev preskúmať príčiny nadmernej predikcie „platný“, potom doplniť ST2 s výberom premís. B1 bol refitovaný na train+dev, B2 trénoval na train a vyberal epochu cez dev; porovnanie má túto hranicu.